

Alessandro Pimentel

ECOSISTEMA DE AUTOMATIZACIÓN IA AUTÓNOMO

SISTEMA DE TRIAGE INTELIGENTE DE TICKETS DE SOPORTE TÉCNICO

26 de junio de 2026

1. DESCRIPCIÓN DEL CASO DE USO Y ARQUITECTURA DEL SISTEMA

Caso de Uso Seleccionado

El ecosistema automatiza el proceso de triage de tickets de soporte técnico de extremo a extrem. Cuando un cliente envía una solicitud, el sistema la recibe, valida, clasifica con IA, actualiza la base de datos, enruta según la prioridad y notifica a los equipos correspondientes sin intervención manual, salvo los casos críticos los cuales si active el punto de validación humana (Human In The Loop)


Problema que resuelve

- Sin automatizar: cada ticket llega por email, un humano lee, clasifica y reenvía manualmente.
- Tiempo perdido: 5-15 minutos por ticket solo en clasificación y enrutamiento.
- Con este sistema: clasificación en menos de 8 segundos, 0 intervención humana en tickets no-críticos.
- Ahorro estimado: 80% del tiempo de clasificación manual en equipos de soporte.

Stack Tecnológico

Componente	Tecnología	Función que cumple
Orquestador	n8n self hosted	Coordina todos los nodos de flujo de automatización
Base de Datos	Airtable	Memoria del sistema, registro de tickets, estados y los logs de error
Motor IA	Gemini 2.5 Flash Lite (Google)	Analiza, clasifica y genera resumen técnico del ticket
Canal salida	Gmail (OAuth 2)	Confirmación del cliente, notificación al equipo y alerta HITL
Trigger	Webhook mediante HTTP POST	Entrada: recibe el JSON del ticket desde los orígenes permitidos

Diagrama del Sistema



2. ESTRUCTURA DE DATOS

Base de Datos Relacional en Airtable

El sistema utiliza dos tablas en Airtable que actúan como la memoria persistente del ecosistema. La sincronización entre ambas es gestionada exclusivamente por el flujo n8n (nunca manualmente).

Tabla 1: Tickets

Campo	Tipo	Valores posibles	Descripción
ID_Ticket	Text (PK)	TKT-{timestamp}	Identificador único generado por n8n al momento de creación
Asunto	Text	Texto libre	Asunto original enviado por el cliente
Email_Cliente	Email	—	Email indexado para búsqueda y envío de confirmación
Nombre_Cliente	Text	—	Nombre del remitente
Descripcion	Long Text	Texto libre	Descripción completa del problema (input para Gemini)
Canal_Entrada	Select	webhook / email / chat	Origen del ticket para estadísticas de canal
Estado	Select	Ver lista abajo	Campo de ciclo de vida — controlado por n8n automáticamente
Prioridad	Select	CRITICA / ALTA / MEDIA / BAJA	Asignada por Gemini según criterios del prompt estructurado
Categoria	Select	BUG / ACCESO / PERFORMANCE /	Clasificación temática del problema

		INTEGRACION / CONSULTA / FACTURACION / SEGURIDAD	
Sentimiento_Cliente	Select	URGENTE / FRUSTRADO / NEUTRAL / SATISFECHO	Análisis de sentimiento de la descripción
Resumen_IA	Long Text	—	Oración técnica concisa generada por Gemini
Accion_Recomendada	Long Text	—	Próximo paso concreto sugerido por la IA al agente
SLA_Horas	Number	1 / 4 / 24 / 72	Tiempo de respuesta comprometido según prioridad
Requiere_Escalacion	Checkbox	true / false	Flag de escalación determinado por Gemini
Tags	Text	Tags separadas por coma	Etiquetas técnicas generadas por IA para búsqueda y filtrado
Timestamp_Analisis	DateTime	ISO 8601	Momento exacto en que Gemini procesó el ticket
Confirmacion_Enviada_Cliente	Checkbox	true / false	Indica si el email de confirmación fue despachado
Notas_Internas	Long Text	—	Comentarios del sistema o del agente (HITL, escalaciones)
Fecha_Creacion	DateTime	ISO 8601	Timestamp de recepción del webhook

Ciclo de vida campo Estado

Estado (gestionado por n8n)	
Pendinet	Ticket recibido y registrado en Airtable (antes del análisis IA)
Procesado por IA	Gemini completó el análisis y actualizó los campos
Esperando Aprobación Humana	Prioridad CRITICA: flujo pausado hasta respuesta del supervisor
Notificado - Pendiente Agente	Email enviado al cliente y al equipo. Aguarda asignación manual
Error	El flujo falló en algún nodo; ver tabla Errores_Log para diagnóstico

Tabla 2: Errores Log

Campo	Tipo	
Timestamp	Date	Fecha exacta del fallo
Nodo_Origen	Text	Nombre del último nodo ejecutado antes del fallo
Tipo_Error	Text	Clase del error (ej: NodeOperationError, AuthenticationError)
Mensaje_Error	Long Text	Mensaje completo del error para diagnóstico
Flujo	Text	Nombre del workflow que generó el error
Estado_Log	Select	Error No Resuelto / Resuelto — actualizado manualmente por el equipo
Datos_Contexto	Long Text	Error No Resuelto / Resuelto — actualizado manualmente por el equipo

Esquema JSON de Transferencia Datos

Input: Payload del Webhook

```
{
  "email": "cliente@empresa.com",
  "nombre": "María García",
  "asunto": "No puedo acceder al panel de control",
  "descripcion": "Desde esta mañana el login devuelve error 403...",
  "canal": "web"
}
```

Output: JSON Gemini una vez procesado después del nodo Code

```
{
  "prioridad": "ALTA",
  "categoria": "ACCESO",
  "sentimiento": "FRUSTRADO",
  "resumen_tecnico": "Error 403 en login del panel de control desde 09:00",
  "accion_recomendada": "Verificar permisos de sesión y tokens JWT activos",
  "sla_horas": 4,
  "requiere_escalacion": false,
  "tags": ["error-403", "autenticacion", "panel"],
  "procesado_por": "gemini-2.5-flash-lite",
  "timestamp_analisis": "2026-06-25T14:32:11.000Z"
}
```

3. ESTRATEGIA DE OPTIMIZACION DE COSTOS Y RECURSOS

No todas las tareas requieren el mismo modelo de IA. Por lo que lo ideal es asignar el mínimo de potencia computacional necesaria para completar cada tarea con calidad suficiente. Un modelo caro en tareas simples significa gastar mas dinero innecesariamente. Un modelo barato en tareas que son muy complejas es un riesgo de calidad.

Comparación Modelos de IA

Modelo	Input \$/MTok	Output \$/MTok	Velocidad	Mejor para
Gemini 2.5 flash lite	\$0.10	\$0.40	Muy rápida	Análisis multi-dimensión, razonamiento estructurado, salida JSON
GPT-4o mini	\$0.15	\$0.60	Rápida	Resúmenes cortos, formateo de texto, traducciones
Google Batch API (Gemini 2.5 Flash-Lite)	\$0.05 (-50%)	\$0.20 (-50%)	Async (24h)	Procesamiento masivo de tickets históricos, re-análisis nocturno
n8n Code Node (sin LLM)	\$0	\$0	Instantánea	Mapeo de datos, formateo de strings, lógica determinista

Decisión de Modelo

Tarea del Ecosistema	Modelo Asignado	Costo / unidad	Volumen diario	Costo/día
Clasificación y triage del ticket (análisis multi-dimensión: prioridad, categoría, sentimiento, SLA, escalación, tags)	Gemini 2.5 Flash-Lite. Relación calidad-precio superior — muy rápido con salida JSON estructurada	~\$0.003	100 tickets	\$0.30
Email de confirmación al cliente (texto template con variables dinámicas del ticket)	n8n Code Node (sin LLM) Tarea mecánica — solo mapeo de variables a template HTML	\$0.000	100 emails	\$0.00
Email notificación equipo de soporte (formato HTML con datos del ticket clasificado)	n8n Code Node (sin LLM) Tarea mecánica — estructura fija, datos del JSON de Gemini	\$0.000	100 emails	\$0.00
Re-clasificación masiva de tickets históricos (análisis retroactivo nocturno)	Google Batch API (Gemini 2.5 Flash-Lite) 50% descuento en procesamiento asíncrono	\$0.0015	1.000 tickets (batch nocturno)	\$1.50
Log de errores y registro en tabla Errores_Log	n8n Code Node + Airtable Lógica determinista — captura de \$json.error	\$0.000	Variable	\$0.0
Email HITL al supervisor (tickets CRÍTICOS únicamente)	n8n Code Node Solo se dispara en tickets CRÍTICOS (< 5% del volumen)	\$0.000	Menos de 5 tickets	\$0.00

Ahorro de presupuesto

Escenario	Costo diario (100 tickets)	Ahorro
Sin optimización: modelo premium (ej. Gemini 3.1 Pro) para triage	~\$1.50 / día	0%

Con optimización: Gemini 2.5 Flash-Lite solo para triage	\$0.30 / día	~80%
Con Batch API nocturna (re-análisis histórico)	\$1.50 / 1.000 tickets	50% vs estándar

4. MALLA SE SEGURIDAD Y PRIVACIDAD

Se aplica el principio de mínimo privilegio en todos los niveles: cada componente accede solo a los datos que necesita para cumplir su función específica.

Capa	Política aplicada	Implementación técnica
Gmail	Autenticación OAuth2, no contraseñas SMTP en texto plano	Nodo Gmail con credential type gmailOAuth2 — scope mínimo (send only)
Airtable	Personal Access Token con scope mínimo a las tablas necesarias	Token vinculado solo a la base appXXXXX, no a toda la cuenta
Gemini API	Clave API solo en credenciales de n8n, nunca en parámetros de nodos	Nodo Gemini con credential nativo; key nunca visible en logs
Datos del cliente	Email y nombre solo usados para envío de confirmación y registro	No se almacenan contraseñas, tarjetas ni datos sensibles adicionales
Logs de error	Errores logueados sin exponer datos del cliente en el mensaje	Tabla Errores_Log captura error.name y error.message, no el payload completo

Error Handler

Se implementa un Error Trigger global que captura cualquier fallo en cualquier nodo del workflow principal. Esto garantiza que ningún error pase desapercibido y que el sistema sea auto-diagnóstico.

- Validacion de entrada: Nodo IF valida email, asunto y descripcion antes de procesar. Si alguno falla, envía respuesta HTTP 400 sin consumir créditos de IA ni escribir en Airtable
- Fallback del parser de IA: El nodo de Code tiene try/catch. Si Gemini devuelve el JSON malformado, el sistema no se detiene, usa valores por defecto (MEDIA / 24 hs / manual-review) y el flujo sigue normalmente, marcando ticket con tag “parse-error”
- Error trigger global: Captura fallos de la red, timeout de la API, de Airtable.

-
- a. Escribe registro en tabla Errores_Log
 - b. Envía un correo al supervisor con nodo origen tipo y el mensaje de error

Humn In The Loop

El punto de validación humana (Human-in-the-Loop) fue insertado en el único momento donde una acción automática puede llegar a generar impacto legal, económico, entre otras cosas significativo: la respuesta a tickets de prioridad CRÍTICA.

Punto HITL	Trigger	Riesgo mitigado	Acción del sistema
Tickets CRÍTICOS	Prioridad = CRITICA (sistema caído, pérdida de datos, acceso bloqueado a producción)	Alucinación de IA: que el sistema clasifique mal como CRÍTICO y escale de forma innecesaria, generando pánico o compromisos no autorizados con el cliente	Flujo se PAUSA. Email al supervisor con análisis IA + descripción original. Estado en Airtable: 'Esperando Aprobación Humana'. Sin contacto con el cliente hasta aprobación.

¿Por qué solo los tickets CRITICOS tienen HITL?

- Los tickets ALTA/MEDIA/BAJA solo reciben un email de confirmación y notificación interna — acciones de bajo riesgo que no comprometen al negocio.
- Aplicar HITL a todos los tickets anularía el beneficio de la automatización (efecto metralleta).
- El prompt de Gemini usa temperatura = 0.1 para minimizar variabilidad en la clasificación de alta-prioridad.

5. ANTI LOOPS

Se usa un Webhook HTTP POST como trigger, lo que previene loops infinitos: cada ticket genera una ejecución. No hay triggers de polling sobre el resultado del mismo flujo.

Checklist de seguridad del flujo

- Filtro de datos completos antes de cualquier procesamiento (no se consumen tokens si el input es inválido)
- Comparación de tipos estricta en los nodos IF
- Prompt de IA 100% dinámico: usa variables del sistema, sin texto hardcodeado
- Max Tokens = 1000 para Gemini (previene respuestas excesivas y costos de mas)
- Temperatura = 0.1 para output mas determinista y clasificaciones consistentes